

PA03: Clustering, Regularization, Dimensionality Reduction

Machine Learning

Jinsun Park

Visual Intelligence and Perception Lab., CSE, PNU

Problem

부산대학교 컴퓨터공학과 학생인 산지니는 봉사 동아리에 들어가 주기적으로 농촌 봉사를 하고 있다. 밀밭에서 열심히 일을 하던 산지니는 여러 가지 밀 씨앗들을 보며 이러한 데이터도 머신러닝에 적용하면 재밌겠다고 생각했다. 산지니는 이번에도 "머(신러닝)잘알(아)" 친구인 당신에게 도움을 요청했다. 머알못 산지니를 위해 이전 수업에서 배운 모델과 지식을 활용하여 도움을 주자.

- 입력
 - 씨앗의 정보가 담긴 CSV 파일 "seeds.csv"가 주어진다.
- 출력
 - CSV 파일 안에 있는 씨앗의 정보를 적절히 활용하여 주어진 예측을 수행하자.
- 제한
 - Todo 1, 2를 모두 구현해야 한다.

Dataset

- Dataset Preview
 - "seeds.csv"
 - 세 가지 다른 밀 품종인 Kama, Rosa 및 Canadian에 대한 정보가 담겨 있습니다.
 - 210 rows x 7 columns

area	perimeter	compactness	len_ker	wid_ker	a_coef	len_ker_gro	label
15.26	14.84	0.871	5.763	3.312	2.221	5.22	1
14.88	14.57	0.8811	5.554	3.333	1.018	4.956	1
14.29	14.09	0.905	5.291	3.337	2.699	4.825	1
13.84	13.94	0.8955	5.324	3.379	2.259	4.805	1
16.14	14.99	0.9034	5.658	3.562	1.355	5.175	1
14.38	14.21	0.8951	5.386	3.312	2.462	4.956	1
14.69	14.49	0.8799	5.563	3.259	3.586	5.219	1
14.11	14.1	0.8911	5.42	3.302	2.7	5	1
16.63	15.46	0.8747	6.053	3.465	2.04	5.877	1

Dataset

- Dataset info.
 - To construct the data, seven geometric parameters of wheat kernels were measured:
 - **area**, A
 - **perimeter**, P
 - **compactness**, $C = \frac{4\pi A}{P^2}$,
 - **len_ker**, length of kernel
 - **wid_ker**, width of kernel
 - **a_coef**, asymmetry coefficient
 - **len_ker_gro**, length of kernel groove.
 - All of these parameters were real-valued continuous.

Todo 1 – Clustering & Dimensionality Reduction

- 주어진 데이터셋을 활용하여 데이터 EDA를 진행하고, 모델 학습을 위한 적절한 형태로 가공해주세요.
 - 불필요한 행 또는 열을 삭제해도 좋고, 필요한 열을 추가하여도 좋습니다.
- 가공한 데이터셋에 PCA와 같은 Dimensionality Reduction method를 적용하세요.
 - 수업에서 배운 기법이나, Dimensionality reduction을 잘 수행할 수 있다면 배우지 않았던 기법을 적용해보아도 좋습니다.
- 최종 데이터를 clustering model을 통해 학습합니다.
 - 이때 데이터를 재가공을 하거나 모델의 하이퍼파라미터를 바꾸는 등 다양한 방법을 사용해 모델의 성능을 향상시키는 경험을 해보시면 좋을 것 같습니다.
- 실험한 결과를 잘 정리하여 보고서를 작성해주세요.

Todo 2 - Regularization

- 주어진 데이터셋을 Regularization 모델 학습을 위한 적절한 형태로 가공해주세요.
 - 불필요한 행 또는 열을 삭제해도 좋고, 필요한 열을 추가하여도 좋습니다.
- 가공한 데이터셋에 Ridge Regression method를 적용해주세요.
 - Regularization을 적용한 모델과 적용하지 않은 모델의 성능을 비교하세요.
 - 이때 데이터를 재가공을 하거나 모델의 하이퍼파라미터를 바꾸는 등 다양한 방법을 사용해 모델의 성능을 향상시키는 경험을 해보시면 좋을 것 같습니다.
- 모델을 적용하여 실험한 결과를 잘 정리하여 보고서를 작성해주세요.
- 작성한 최종 보고서 및 코드를 PLATO에 제출해주세요.

Submission

- Submission form
 - 코드 구현 및 실행 후 실험에 대한 실행 결과가 저장된 형태인 ipynb 파일.
 - 그림, 표 등을 포함하는 보고서를 작성하여 제출하나, 분량은 그림, 표 등을 제외한 텍스트 기준 최소 워드 2장 이상의 분량으로 제출.
 - 각각의 알고리즘에 대한 성능 평가 및 결과 분석 내용 포함.
 - (Optional) 현재 머신러닝 수업을 수강중인 동료에게 도움을 받았을 경우, 동료의 학번/이름 작성.
 - 추후 표절 시비를 방지하기 위함.
 - 과제 제출 기한은 2024.06.09(일) 23:59 까지 입니다.
 - 추가 제출은 데드라인 이후 1일 이내이며, 점수의 50%가 감점됩니다.

Good Luck